Персонализация диффузионных моделей через редактирование весов cross-attention

Карина Пескова
МГУ имени М. В. Ломоносова
Факультет вычислительной математики и кибернетики
Москва, Россия

Abstract

Персонализированная генерация изображений предполагает адаптацию предобученной диффузионной модели к конкретному объекту по небольшому набору его фотографий. Методы дообучения, такие как DreamBooth, позволяют запоминать индивидуальные особенности объекта, но требуют оптимизации параметров и могут изменять генерацию по запросам, не связанным с новым объектом. В данной работе исследуется подход, основанный на аналитическом редактировании матриц ключей и значений (`to_k`, `to_v`) в слоях cross-attention модели Stable Diffusion. Сначала с помощью DreamBooth LoRA обучается персонализированная модель-учитель, затем её линейные преобразования текстовых представлений переносятся в базовую модель с использованием проекции на ортогональное дополнение к подпространству сохраняемых текстовых признаков. Для вычисления поправок используется регуляризованная задача наименьших квадратов с аналитическим решением. Предварительные эксперименты на персонализации изображения собаки показывают, что такое редактирование позволяет перенести некоторые индивидуальные признаки и при этом визуально сохранить результаты на обычных запросах. Однако полнота воспроизведения объекта уступает модели-учителю; выявлена также зависимость результата от способа формирования сохраняемого подпространства.

Ключевые слова: персонализированная генерация, диффузионные модели, Stable Diffusion, DreamBooth, LoRA, AlphaEdit, редактирование весов, нуль-пространство.

1 Введение

Современные text-to-image модели позволяют генерировать разнообразные изображения по текстовому описанию, однако обычно не умеют воспроизводить конкретный, ранее не встречавшийся объект с сохранением его индивидуальных особенностей. Задача персонализации состоит в том, чтобы по нескольким фотографиям субъекта связать его внешний вид с уникальным текстовым идентификатором и затем использовать этот идентификатор в новых сценах, позах и условиях освещения.

В DreamBooth [?] эта задача решается путём дообучения диффузионной модели. Параметрически эффективная адаптация с помощью LoRA [?] уменьшает число обучаемых параметров, но не отменяет саму необходимость итеративного обучения. При этом желательны одновременно высокая точность воспроизведения нового субъекта и сохранение поведения исходной модели для остальных запросов.

39th Conference on Neural Information Processing Systems (NeurIPS 2025).

Альтернативное направление — редактирование уже существующих весов модели. Работа AlphaEdit [?] предлагает ограничивать обновления проекцией на нуль-пространство представлений знаний, которые необходимо сохранить. Хотя метод разработан для языковых моделей, идея ограничения направления обновления применима и к линейным преобразованиям в диффузионных моделях. Результаты анализа text-to-image моделей [?] также мотивируют исследование локального редактирования параметров вместо полного переобучения сети.

В настоящей работе рассматривается следующий компромисс: можно ли перенести персонализацию из уже обученной LoRA-модели в базовую Stable Diffusion посредством аналитического изменения только линейных проекций ключей и значений cross-attention, минимально затрагивая обычную генерацию? В отличие от подхода, использующего визуальные признаки как непосредственные целевые выходы, здесь персональная информация передаётся через преобразования текстовых признаков, полученные от модели-учителя.

Основные результаты работы. Реализован метод переноса весовых преобразований от DreamBooth LoRA к базовой диффузионной модели с нуль-пространственной проекцией; сформулирована аналитически решаемая задача редактирования; проведены предварительные качественные эксперименты с различными чекпоинтами модели-учителя и вариантами текстового корпуса для построения проектора. Выявлено, что сильное ограничение разрешённых направлений обновления может препятствовать переносу нового концепта даже при хорошем сохранении исходного поведения.

2 Постановка задачи

2.1 Персонализация и сохраняемые знания

Пусть $G_{\theta_0}(c, z)$ — предобученная text-to-image диффузионная модель, генерирующая изображение по текстовому условию c и случайному входу z. Дан небольшой набор изображений одного субъекта $\mathcal{D}_{\text{pers}} = \{x_1, \ldots, x_N\}$ и его уникальный идентификатор v_*. Требуется получить модель G_{θ_E}, которая удовлетворяет двум требованиям:

- Персонализация: по промптам с v_* модель воспроизводит индивидуальные особенности субъекта и допускает изменение сцены и контекста.
- Сохранение исходного поведения: по промптам без v_* результаты должны оставаться близкими к генерациям G_{θ_0}.

В экспериментальной постановке используется Stable Diffusion v1.4 [?], а персональным субъектом является собака породы корги. Текстовый идентификатор в основных экспериментах — `zjw`. Пример персонального запроса: `a photo of zjw dog on the beach`; соответствующий обычный запрос: `a photo of a dog on the beach`.

2.2 Редактируемые параметры

В блоке cross-attention скрытые состояния текстового энкодера $H \in \mathbb{R}^{n \times d}$ преобразуются в ключи и значения:

$$K = HW_K^\top, \qquad V = HW_V^\top, \tag{1}$$

где $W_K, W_V \in \mathbb{R}^{d_{\text{out}} \times d}$. Исследуется изменение только матриц $W_{l,K}$ и $W_{l,V}$ во всех выбранных cross-attention слоях U-Net; остальные параметры при аналитическом редактировании остаются равными исходным.

Для каждого редактируемого слоя l и типа проекции $s \in \{K, V\}$ обозначим базовые веса через $W_{l,s}^{(0)}$, а эффективные веса персонализированной LoRA-модели-учителя через $W_{l,s}^{(T)}$. Последние получаются после обычного обучения DreamBooth LoRA на $\mathcal{D}_{\text{pers}}$. Таким образом, изображения субъекта используются при обучении учителя, но аналитическая стадия переноса работает с текстовыми представлениями и весами моделей, без нового диффузионного обучения.

2.3 Текстовые матрицы и проектор

С помощью токенизатора и CLIP text encoder формируются две матрицы:

$$X_{\text{pers}} \in \mathbb{R}^{n_p \times d}, \qquad X_0 \in \mathbb{R}^{n_0 \times d}. \tag{2}$$

Строки X_{pers} — векторные представления выбранных токенов персональных промптов, а строки X_0 — представления обычных промптов, поведение на которых необходимо сохранить. Для Stable Diffusion v1.4 размерность текстового представления составляет $d = 768$.

Пусть усечённое сингулярное разложение X_0 позволяет выбрать r правых сингулярных векторов $V_r \in \mathbb{R}^{d \times r}$, соответствующих сохраняемым направлениям. Рассмотрим ортогональный проектор

$$P = I_d - V_r V_r^\top, \qquad P^\top = P, \quad P^2 = P. \tag{3}$$

Он подавляет выбранное подпространство старых текстовых представлений. При $PX_0^\top = 0$ любое обновление вида ΔP в точности сохраняет выходы редактируемой линейной проекции на X_0. При усечённом выборе ранга это свойство может выполняться лишь приближённо. Речь идёт именно о сохранении линейных выходов на заданных представлениях, а не о гарантии идентичности произвольных сгенерированных изображений.

2.4 Аналитическое обновление весов

Цель — приблизить преобразования, реализуемые учителем на X_{pers}, не выходя за рамки разрешённого проектором подпространства. Для каждого l, s решается задача

$$\Delta_{l,s}^* = \arg\min_{\Delta} \left\{ \left\| (W_{l,s}^{(0)} + \Delta P) X_{\text{pers}}^\top - W_{l,s}^{(T)} X_{\text{pers}}^\top \right\|_F^2 + \lambda \left\| \Delta \right\|_F^2 \right\}, \tag{4}$$

где $\lambda > 0$ — коэффициент регуляризации. Введём обозначения

$$Z = PX_{\text{pers}}^\top \in \mathbb{R}^{d \times n_p}, \qquad R_{l,s} = (W_{l,s}^{(T)} - W_{l,s}^{(0)}) X_{\text{pers}}^\top. \tag{5}$$

Тогда задача (4) является ridge-регрессией $\min_\Delta \left\| \Delta Z - R_{l,s} \right\|_F^2 + \lambda \left\| \Delta \right\|_F^2$ с аналитическим решением

$$\Delta_{l,s}^* = R_{l,s} Z^\top (ZZ^\top + \lambda I_d)^{-1}, \qquad W_{l,s}^{(E)} = W_{l,s}^{(0)} + \Delta_{l,s}^* P. \tag{6}$$

Задача решается независимо для каждой из редактируемых матриц `to_k` и `to_v`. Все остальные веса базовой модели сохраняются без изменений.

Важное ограничение следует из (5): если $PX_{\text{pers}}^\top \approx 0$, то у оптимизации почти нет направлений, по которым можно перенести разницу между учителем и базовой моделью. Для диагностики используются относительные нормы

$$\rho_0 = \frac{\left\| X_0 P \right\|_F}{\left\| X_0 \right\|_F}, \qquad \rho_p = \frac{\left\| X_{\text{pers}} P \right\|_F}{\left\| X_{\text{pers}} \right\|_F}. \tag{7}$$

Малое ρ_0 желательно для сохранения исходных преобразований, а слишком малое ρ_p указывает на риск подавления персонализации.

3 Эксперименты

3.1 Экспериментальная установка

В качестве базовой модели используется Stable Diffusion v1.4. Модель-учитель получена дообучением DreamBooth LoRA на фотографиях одной собаки породы корги. Для одного из основных запусков использовались разрешение 512×512, размер батча 1, скорость обучения $5 \cdot 10^{-5}$ и ранг LoRA 64. Для сравнения сохранены чекпоинты после 400, 800 и 1600 шагов обучения.

Таблица 1: Рассмотренные способы формирования матрицы сохраняемых представлений X_0 и наблюдаемые ограничения.

Источник X_0	Размер матрицы	Качественное наблюдение
Ручные промпты	118×768	Проектор допускает перенос части признаков субъекта.
LAION captions	15642×768	При испытанной настройке проекции персональные направления почти подавляются; перенос концепта затрудняется.

Сравниваются три варианта: Base — исходная модель; LoRA target — персонализированный учитель; AlphaEdit — базовая модель после решения (6). В аналитическом методе изменяются только `to_k` и `to_v` в cross-attention блоках U-Net.

Качественная проверка проводится для персональных запросов `a photo of zjw dog on the beach`, `a photo of zjw dog wearing sunglasses`, `a photo of zjw dog sleeping` и соответствующих запросов без идентификатора `zjw`. Для воспроизводимого попарного сравнения использовались фиксированные значения генератора случайных чисел: 42, 43 и 44.

3.2 Выбор персональных и сохраняемых представлений

Первоначально X_{pers} строилась из эмбеддингов идентификаторного токена (`identifier_only`). Также исследован вариант из всех содержательных токенов персональных промптов (`all_valid`), позволяющий учитывать текстовый контекст. По предварительной визуальной оценке второй вариант переносит больше индивидуальных признаков субъекта.

Для X_0 рассмотрены два источника. Малый вручную составленный корпус обычных промптов даёт матрицу размерности 118×768. При использовании примерно тысячи подписей из поднабора LAION получена матрица размерности 15642×768. Увеличение корпуса расширяет подпространство сохраняемых признаков, но может уменьшать доступные направления редактирования.

3.3 Качественные результаты

Проведённое визуальное сравнение показывает, что аналитическое редактирование передаёт некоторые признаки персональной собаки, в частности характерный окрас и общую форму, однако полученные изображения пока заметно отличаются от генераций DreamBooth LoRA. Увеличение числа шагов обучения учителя само по себе не устранило этого разрыва: для чекпоинтов 800 и 1600 точность переноса не стала сопоставимой с учителем.

На обычных запросах без уникального идентификатора изображения после редактирования визуально близки к изображениям базовой модели. Это согласуется с предположением об ограничении изменений за счёт проектора, но не является количественным доказательством сохранения всех свойств модели.

3.4 Ограничения и дальнейшие эксперименты

Полученные результаты указывают на противоречие между сохранением предобученных преобразований и переносом нового субъекта. Большой корпус X_0 может охватывать направления, необходимые для персонального объекта: в таком случае проектор одновременно подавляет нежелательные изменения и полезный сигнал модели-учителя. Кроме того, перенос только линейных проекций K и V может не воспроизводить изменения учителя, распределённые по другим весам U-Net.

Следующий этап исследования — количественное сравнение качества персонализации и сохранения исходного поведения, а также абляции регуляризации λ, числа сохраняемых сингулярных направлений r, размера и состава корпуса X_0 и способа отбора токенов

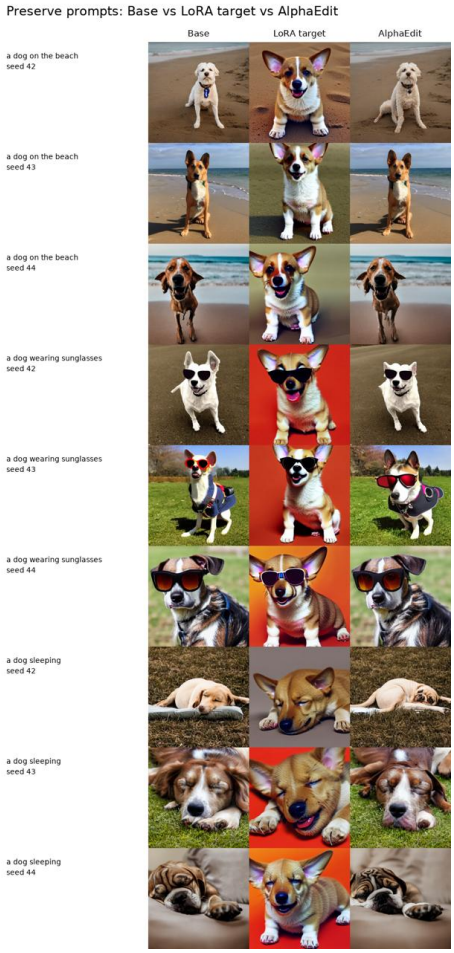


Рис. 1: Качественное сравнение моделей Base, LoRA и AlphaEdit. Для каждой строки фиксируются промпт и случайный seed; меняется только вариант модели.

для X_{pers}. Эти абляции относятся к планируемым экспериментам; количественные результаты для них в настоящем тексте не заявляются.

Список литературы